التعليم باشراف و بدون اشراف

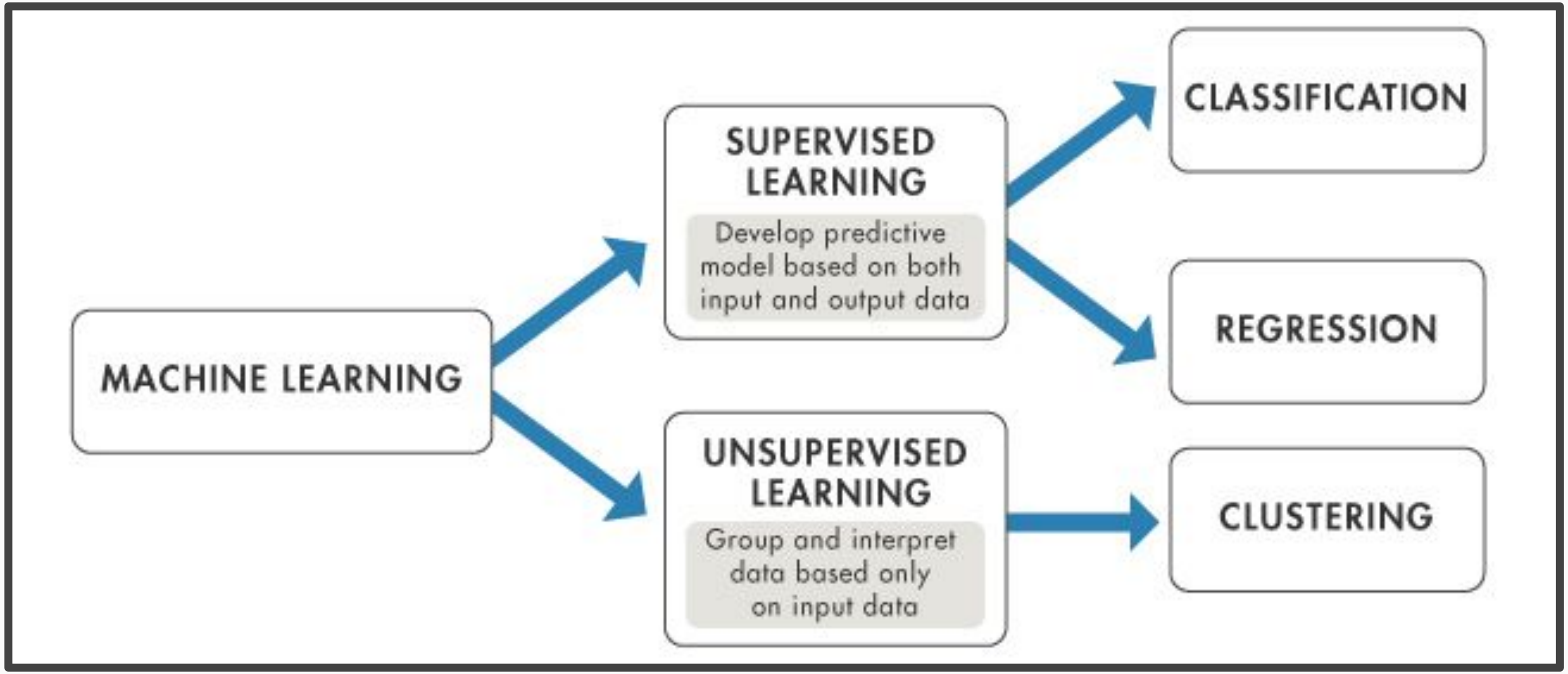

Regression التوقع

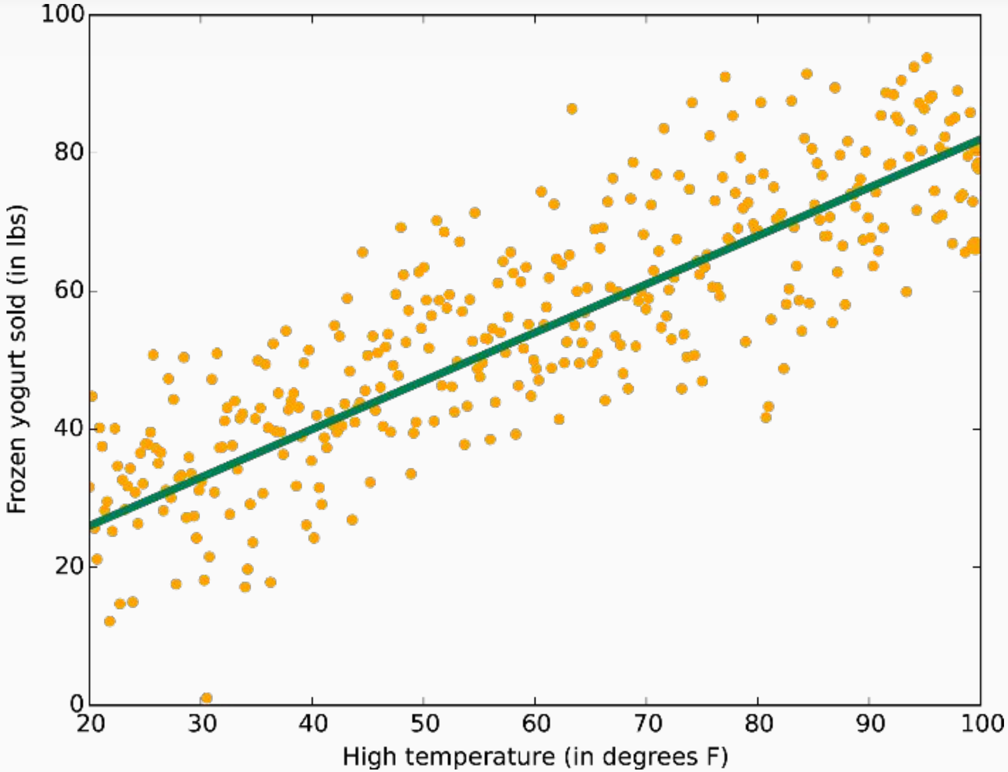

Regression التوقع

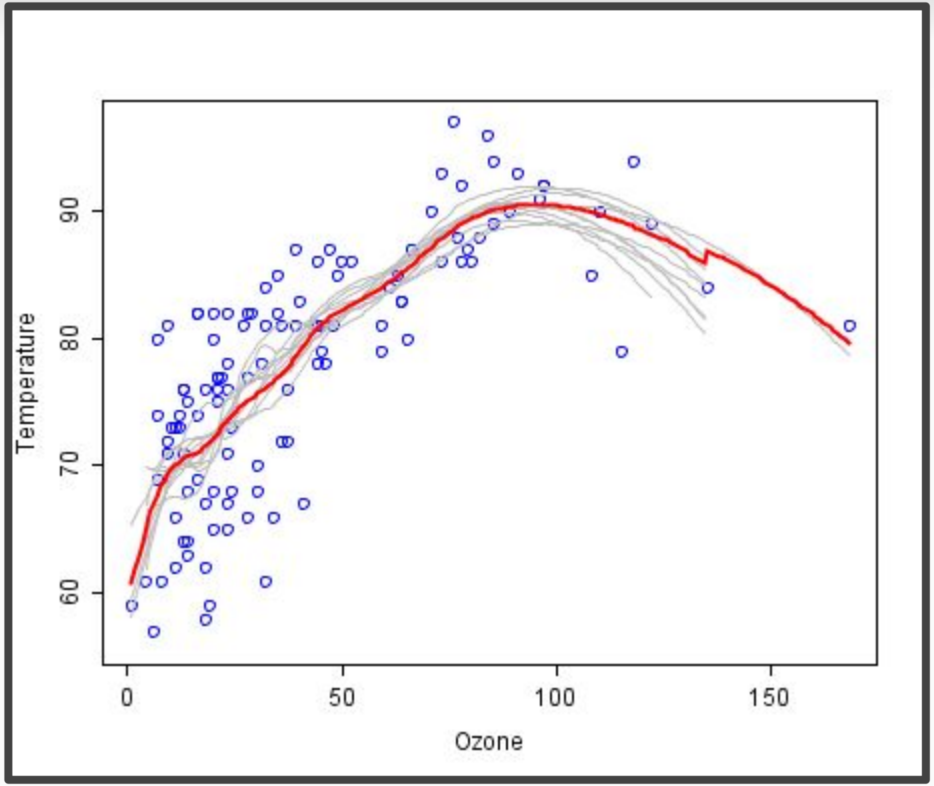

التوقع Regression

تطبيقات التوقع :

- اسعار البيوت
- أسعار الاسهم في البورصة
- حالة الطقس
- المبلغ الذي سيشتري به العميل

Linear Regression التوقع الخطي

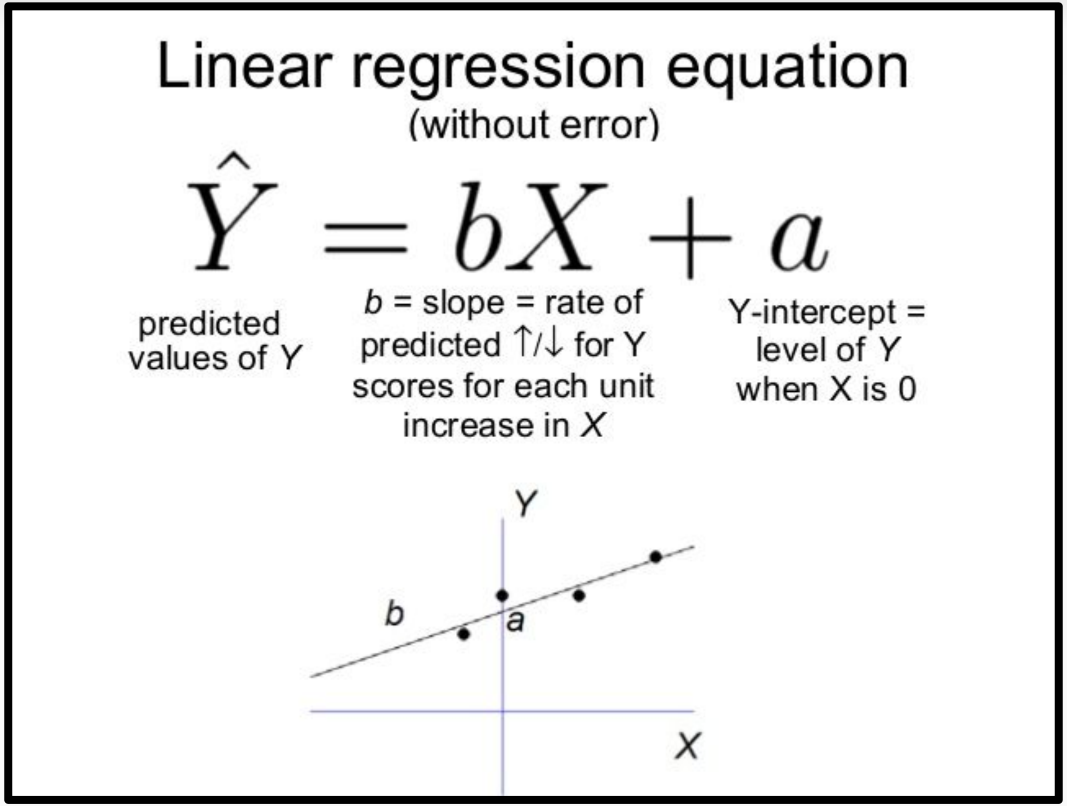

- و يسمي أيضا (One Varilable Regression) او (Unvariate Regression)

Linear Regression التوقع الخطي

Input X	المدخلات
Output Y	المخرجات
Rows m	الصفوف
Features n	العناصر
h(x)	القيمة المتوقعة
Cost J	قيمة الخطأ
Theta Θ	معاملات الـ X

Linear Regression Equation معادلة التوقع الخطي

Hypothesis: $h_\theta(x) = \theta_0 + \theta_1 x$

Parameters: θ_0, θ_1

Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right)^2$

Goal: $\underset{\theta_0, \theta_1}{\text{minimize}}\ J(\theta_0, \theta_1)$

- الهدف تقليل الفارق بين قيمة h(x) و هي القيمة المتوقعة من المعادلة الخطية و قيمة y و هي القيمة الحقيقية
- يتم القسمة علي 2m لربط قيمة الخطا بعدد القيم بالعينة
- الهدف ايجاد قيم ثيتا 1 و ثيتا 2 , والتي تجعل من J (نسبة الخطا) اقل ما يمكن
- تسمي احيانا Cost error function

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2   Equation $h(x) = 5 + 2x$

X	Y	h(x)	h(x) - y	$(h(x) - y)^2$
1	7			
2	8			
2	7			
3	9			
4	11			
5	10			
5	12			

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2 Equation $h(x) = 5 + 2x$

X	Y	h(x)	h(x) - y	$(h(x) - y)^2$
1	7	7		
2	8	9		
2	7	9		
3	9	11		
4	11	13		
5	10	15		
5	12	15		

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2 Equation $h(x) = 5 + 2x$

X	Y	h(x)	h(x) - y	$(h(x) - y)^2$
1	7	7	0	
2	8	9	1	
2	7	9	2	
3	9	11	2	
4	11	13	2	
5	10	15	5	
5	12	15	3	

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2   Equation $h(x) = 5 + 2x$

X	Y	h(x)	h(x) - y	$(h(x) - y)^2$
1	7	7	0	0
2	8	9	1	1
2	7	9	2	4
3	9	11	2	4
4	11	13	2	4
5	10	15	5	25
5	12	15	3	9

Linear Regression Equation معادلة التوقع الخطي

Theta0 = 5 , theta 1 = 2 Equation h(x) = 5 + 2x

X	Y	h(x)	h(x) - y	$(h(x) - y)^2$
1	7	7	0	0
2	8	9	1	1
2	7	9	2	4
3	9	11	2	4
4	11	13	2	4
5	10	15	5	25
5	12	15	3	9

$$\boxed{J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right)^2}$$

J = 1 / 14 (0+1+4+4+4+25+9)

J = 47/14 = 3.3

Best fit line الخط الأكثر ملائمة

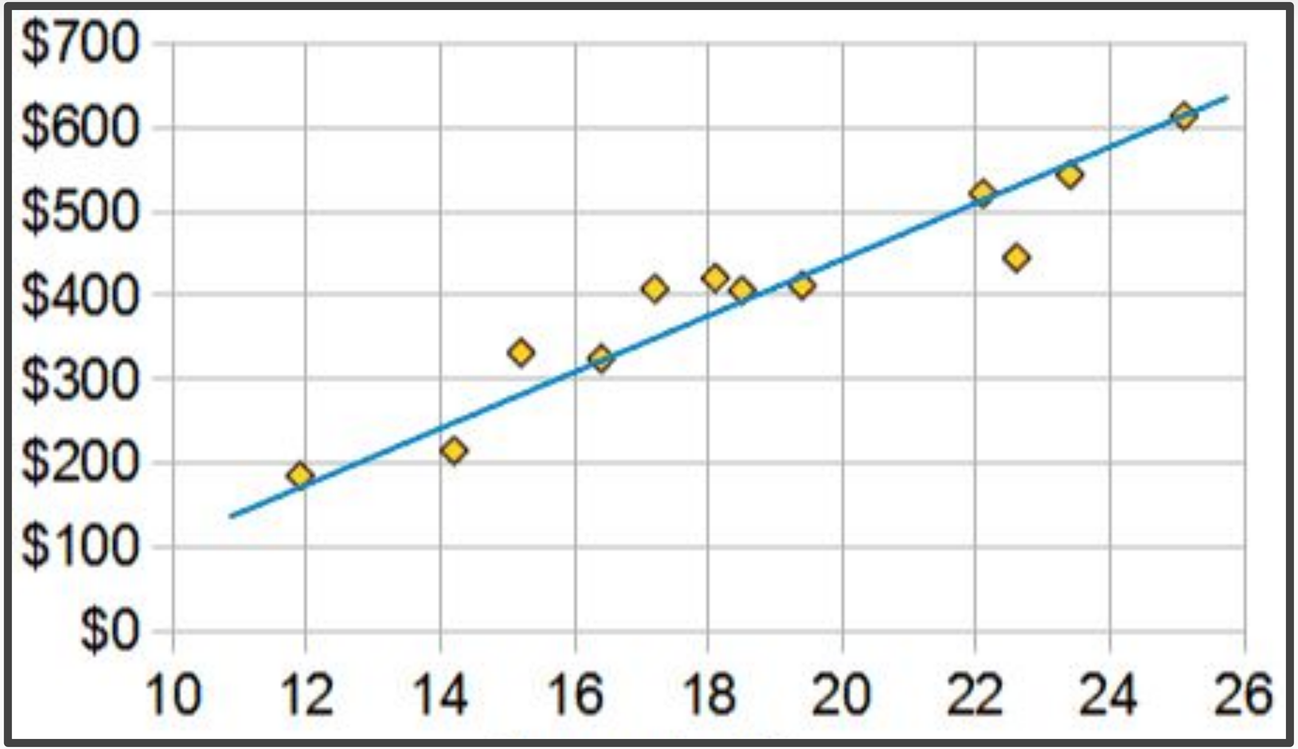

Gradient Descent الإنحدار التدريجي

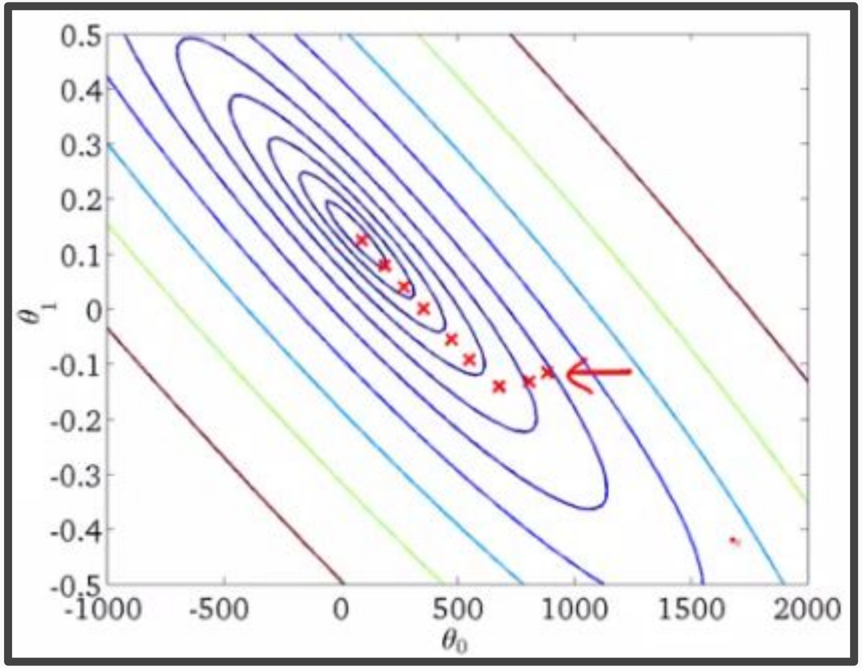

الانحدار التدريجي :

- طالما نحن نبحث عن قيم ثيتا 0 و 1 التي ستقلل قيمة J باقصي قدر , فسنفرض قيم لثيتا 1 و 2 , ثم نقوم بتقليلها تدريجيا حتي نصل لاقل قيمة للـ J

معادلة الإنحدار التدريجي

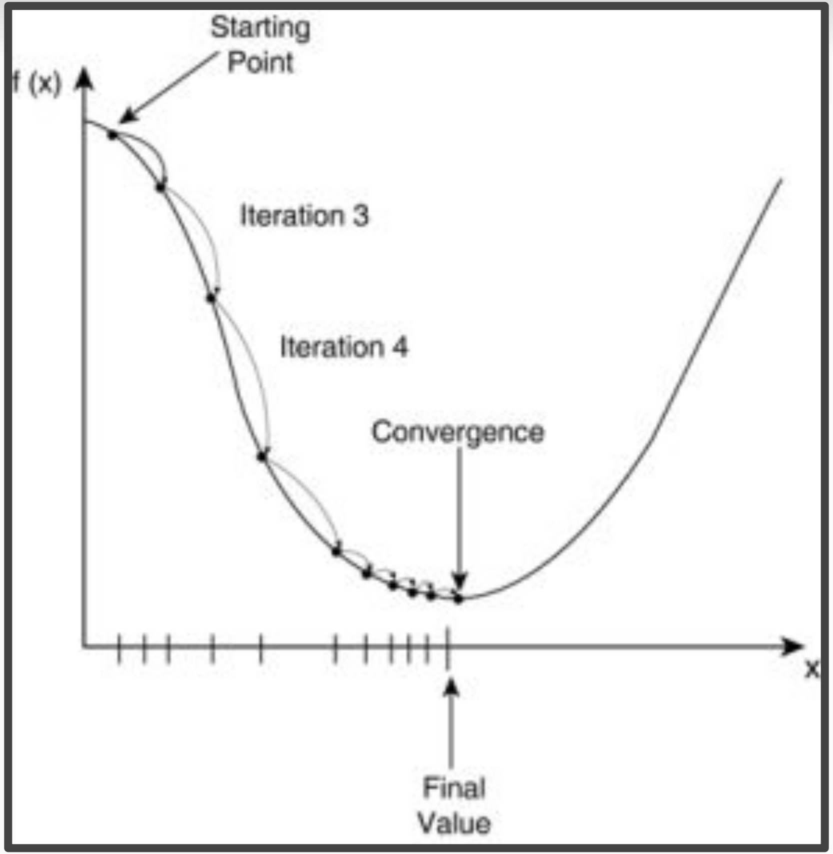

الفكرة :

- لاحظ ان في حالة القيمة الدنيا قيمة التفاضل بصفر (لأن وقتها هيكون الخط شبه مستقيم فالميل هيكون تقريبا 0)
- لاحظ ان قيمة التفاضل تقل كلما قل الميل (التفاضل هو ميل الخط المستقيم, فتدريجيا هيقل قيمة التفاضل لتغير الميل) , وكلما اقترب من القيمة الدنيا , فلا داعي لتقليل الالفا , فالقيمة نفسها ستقل تدريجيا

معادلة الإنحدار التدريجي

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i) x_i)$$

مثال عملي

السعر (الف $) Y	مساحة البيت ($م^2$) X_1
135	100
130	95
110	90
95	80
90	80
85	70
80	70
80	60

- لاحظ ان المساحة اكس , بينما السعر هو واي
- عشان اعمل best fit line هنفرض الثيتات قيم معينة , وليكن ثيتا 0 = 1 و ثيتا 1= 3
- المعادلة هتكون :

h(x) = 1 + 3 X

مثال عملي

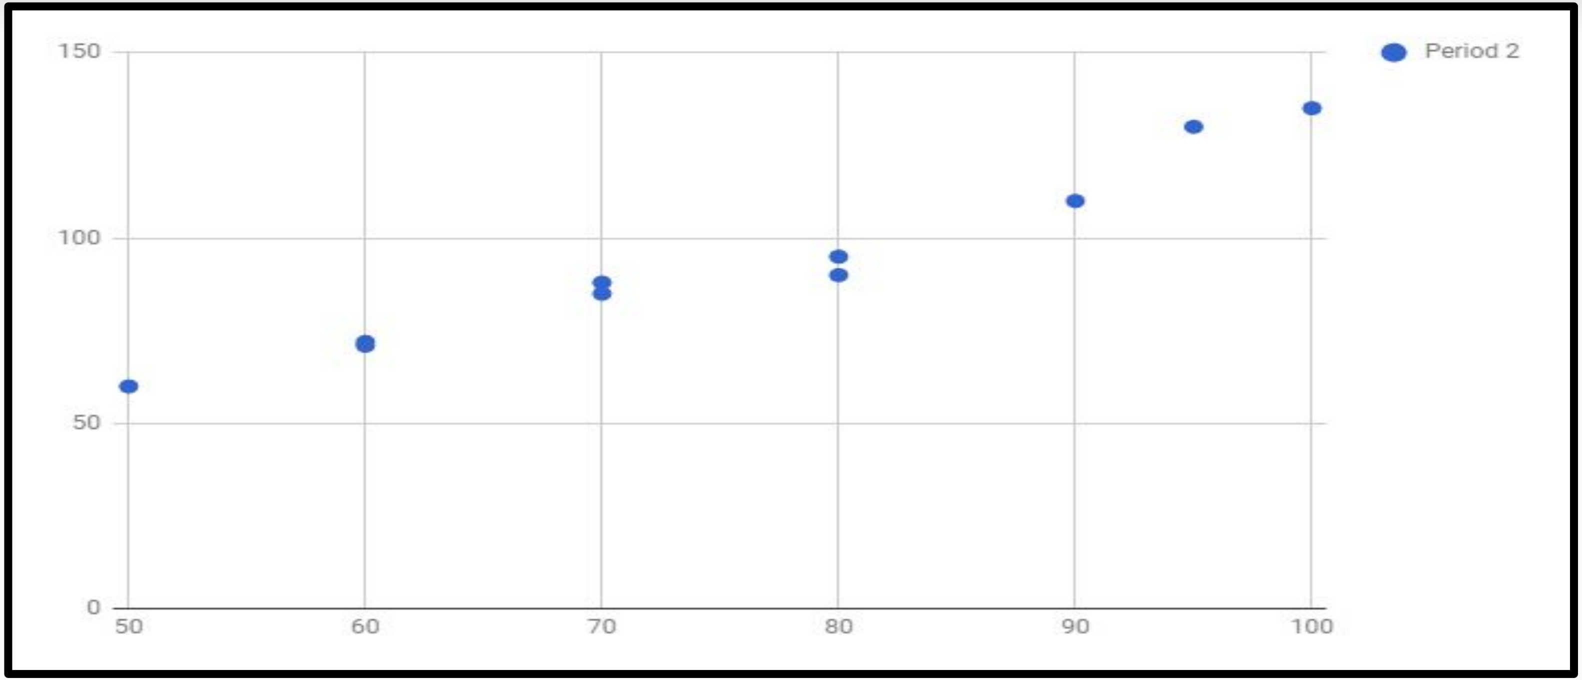

مثال عملي

X_1	Y	h(x)	h(x) -y
100	300		
95	285		
90	270		
80	240		
80	235		
70	200		
70	205		
60	180		

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

ثيتا 0 = 1

ثيتا 1 = 3

المعادلة

h(x) = 1 + 3 X

مثال عملي

X_1	Y	h(x)	h(x) -y
100	300	301	1
95	285	286	1
90	270	271	1
80	240	241	1
80	235	241	6
70	200	211	11
70	205	211	6
60	180	181	1

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

ثيتا 0 = 1

ثيتا 1 = 3

المعادلة

h(x) = 1 + 3 X

مثال عملي

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

ثيتا 0 = 1

مجموع الفروق = 28

الفا = 0.002

قيمة m = 8

Theta 0 = 1 - ((0.002 / 8) * (28))

Theta 0 = 1 - 0.007 = 0.993

مثال عملي

X_1	Y	h(x)	h(x) -y	(h(x) -y)x
100	300	301	1	100
95	285	286	1	95
90	270	271	1	90
80	240	241	1	80
80	235	241	6	480
70	200	211	11	770
70	205	211	6	420
60	180	181	1	60

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i)x_i)$$

ثيتا 0 = 1

ثيتا 1 = 3

مثال عملي

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i)x_i)$$

ثيتا 1 = 0

مجموع الفروق = 2095

الفا = 0.002

قيمة m = 8

Theta 1 = 3 - ((0.002 / 8) * (2095)

Theta 1 = 3 - 0.52 = 2.48

مثال عملي

Theta 0 = 1 Theta 1 = 3

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i) x_i)$$

مثال عملي

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i) x_i)$$

Theta 0 = 1 Theta 1 = 3

Theta 0 = 0.993 Theta 1 = 2.48

مثال عملي

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i)x_i)$$

Theta 0 = 1 Theta 1 = 3

Theta 0 = 0.993 Theta 1 = 2.48

Theta 0 = 0.991 Theta 1 = 2.46

مثال عملي

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x_i) - y_i)$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} ((h_\theta(x_i) - y_i) x_i)$$

Theta 0 = 1 Theta 1 = 3

Theta 0 = 0.993 Theta 1 = 2.48

Theta 0 = 0.991 Theta 1 = 2.46

..

..

Theta 0 = 0.825 Theta 1 = 1.772

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

التعامل مع اكثر من بعد :

- تحدثنا سابقا , عن التعامل مع متغير واحد (قيمة لـ X و نجيب منها قيمة Y) الان نتعامل مع اكثر من متغير
- أكثر من متغير معناها ان البيانات الداخلة لها اكثر معلومة لكل صف , فبدلا من ادخال مساحة البيت لمعرفة سعره (X واحدة) , نقوم بادخال مساحة البيت و عدد غرفه , وعمره, و موقعه , وحالته , ولونه , لتحديد سعره , وهذه الأشياء تسمي features

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

Multiple features (variables).

Size (feet²) x_1	Number of bedrooms x_2	Number of floors x_3	Age of home (years) x_4	Price ($1000) y
2104	5	1	45	460
1416	3	2	40	232
1534	3	2	30	315
852	2	1	36	178
...	...	...	...	...

$m = 47$

Notation:

n = number of features $n = 4$

$x^{(i)}$ = input (features) of i^{th} training example.

$x_j^{(i)}$ = value of feature j in i^{th} training example.

التعامل مع اكثر من بعد :

- فنري ان سعر البيت (Y) يتاثر بعدد من العوامل (Features Xs)
- عدد الاكسات نسميه n, بينما عدد الصفوف لازال m

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$$x_j^{(i)} = \text{value of feature } j \text{ in the } i^{th} \text{ training example}$$

- الرقم اللي فوق يكون رقم الصف (انهي ريكورد فيهم m) و الرقم اللي تحت هيكون رقم العمود (انهي معلومة فيهم n)

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

- القانون الجديد

repeat until convergence: {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_1^{(i)}$$

$$\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_2^{(i)}$$

$\cdots$

}

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

- الصيغة المجمعة

repeat until convergence: {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)} \qquad \text{for j := 0...n}$$

}

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

سعر السيارات :

- عدد السيارات 5 (m)
- المعلومات عن كل سيارة 3 (features n)

X_1	X_2	X_3	Y
العمر	القدرة	الاسطوانات	السعر
5	20	6	12
5	35	6	14
6	38	8	16
7	40	8	15
7	46	10	20

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

X_1	X_2	X_3	Y
العمر	القدرة	الاسطوانات	السعر
5	20	6	114
5	35	6	120
6	38	8	123
7	40	8	121
7	46	10	135

X_1	X_2	X_3
1	1	1
5	5	6
20	35	38
6	6	8

X_4	X_5
1	1
7	7
40	46
8	10

Theta

Theta0	5
Theta1	2
Theta2	3
Theta3	6

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

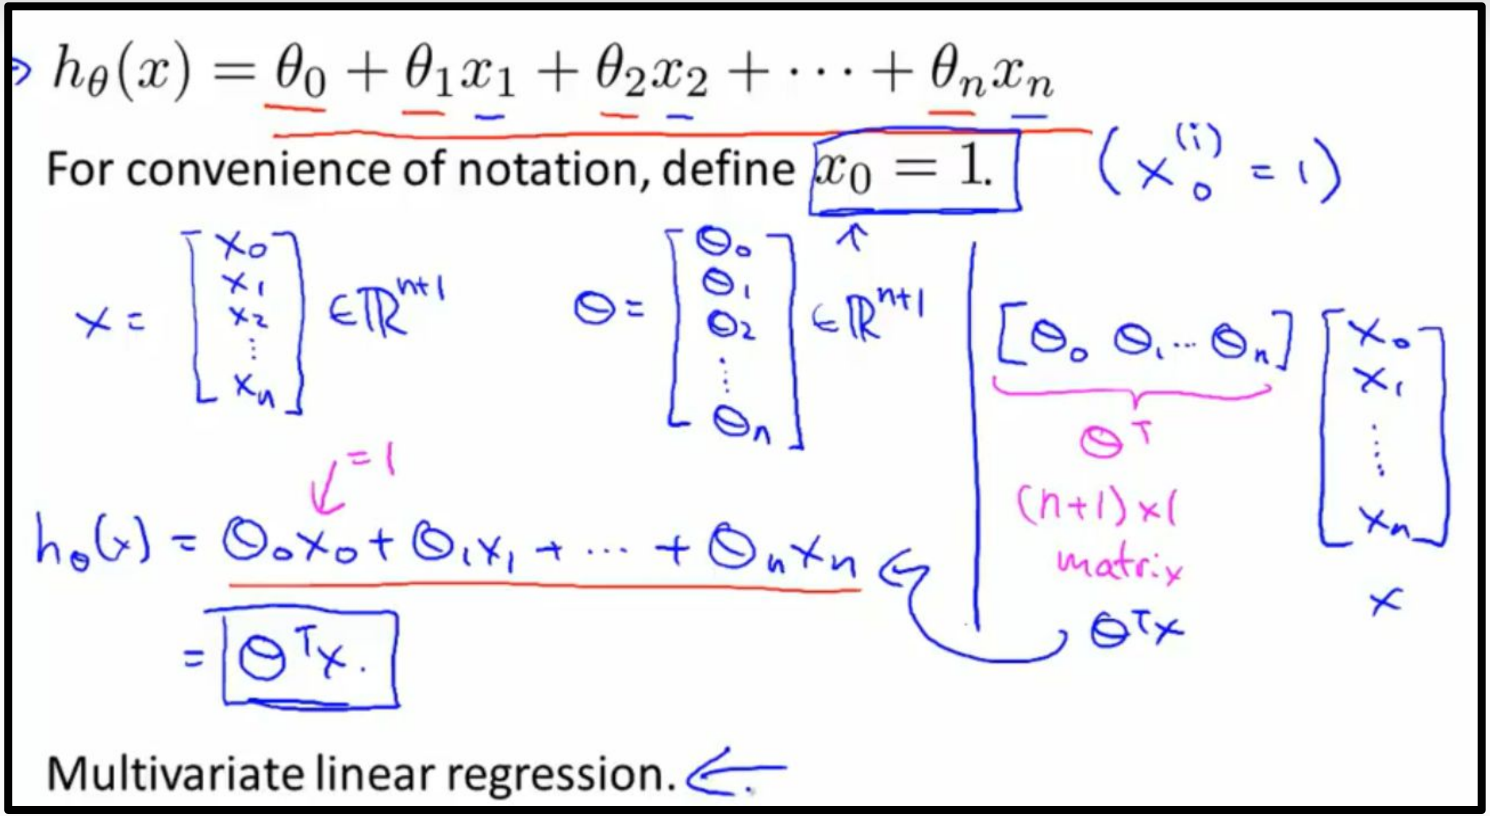

- وقتها الفنكشن , هتكون متعددة الحدود زي كدة , وهنعمل ماتركس للاكسات , وواحدة للثيتات , ونضربهم في بعض بعد ما نعمل ترانزبوس للثيتا

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$h(x) = (\text{Theta})^T X$

$$(\text{Theta})^T = \begin{pmatrix} 5 \\ 2 \\ 3 \\ 6 \end{pmatrix}^T = (5\ 2\ 3\ 6) \qquad X_1 = \begin{pmatrix} 1 \\ 5 \\ 20 \\ 6 \end{pmatrix}$$

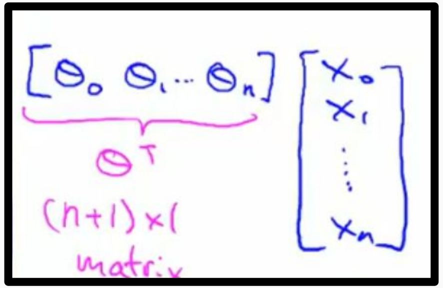

$$h(x)_1 = (5\ 2\ 3\ 6) \begin{pmatrix} 1 \\ 5 \\ 20 \\ 6 \end{pmatrix} = 5*1 + 2*5 + 3*20 + 6*6 = 111$$

$h(x)_1 = 111 \quad h(x)_2 = 119 \quad h(x)_3 = 127 \quad h(x)_4 = 122 \quad h(x)_5 = 140$

التوقع الخطي لأكثر من متغير Linear Regression with Multivariables

- القانون الجديد

repeat until convergence: {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_1^{(i)}$$

$$\theta_2 := \theta_2 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_2^{(i)}$$

$\cdots$

}

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

Suppose Alpha = 0.01   m = 5

Theta 0 = 5 - (0.01 /5)   [(111-114) + (119-120) + (127-123)+ (122-121)+ (140-135) (1)] = 4.9

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

Suppose Alpha = 0.01 m = 5

Theta 0 = 5 - (0.01 /5) [(111-114) + (119-120) + (127-123)+ (122-121)+ (140-135) (1)] = 4.9

Theta 1 = 2 - (0.01 /5) [(111-114) + (119-120) + (127-123)+ (122-121)+ (140-135) (5)] = 2.6

Theta 2 = 3 - (0.01 /5) [(111-114) + (119-120) + (127-123)+ (122-121)+ (140-135) (20)] = 3.9

Theta 3 = 6 - (0.01 /5) [(111-114) + (119-120) + (127-123)+ (122-121)+ (140-135) (6)] = 6.4

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

Suppose Alpha = 0.01   m = 5

Theta 0 = 4.9

Theta 1 = 2.6

Theta 2 = 3.9

Theta 3 = 6.4

Linear Regression with Multivariables التوقع الخطي لأكثر من متغير

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

Suppose Alpha = 0.01   m = 5

Theta 0 = 4.9	Theta 0 = 4.7	Theta 0 = 4.68	Theta 0 = 4.6236
Theta 1 = 2.6	Theta 1 = 2.55	Theta 1 = 2.542	Theta 1 = 2.5398
Theta 2 = 3.9	Theta 2 = 3.87	Theta 2 = 3.863	Theta 2 = 3.8605
Theta 3 = 6.4	Theta 3 = 6.36	Theta 3 = 6.357	Theta 3 = 6.35721

Number of Iteration عدد المحاولات

ما هو العدد المناسب ؟

- من الواضح ان كل ما بنحاول اكتر , قيمة J بتقل و ديه حاجة كويسة
- بس كل ما يزيد عدد المحاولات , كل ما التكلفة و الوقت يزيدو . وده عيب كبير
- يبقي نحاول كام مرة ؟ ؟

Number of Iteration عدد المحاولات

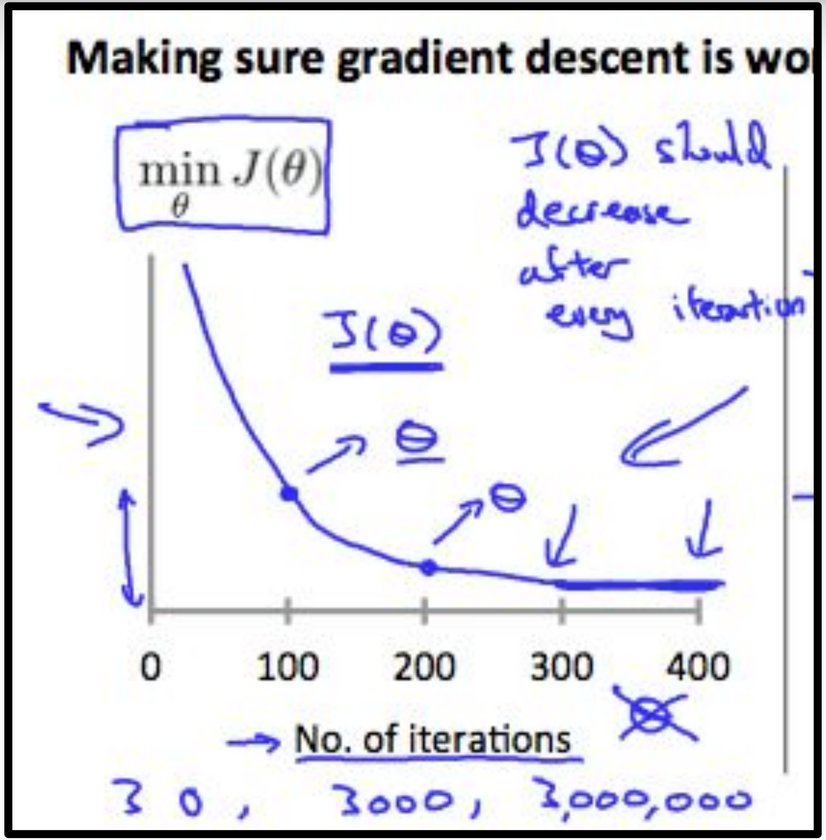

ما هو العدد المناسب ؟

- الرسمة هنا واضح فيها ان كل ما بنزود عدد المحاولات , كل ما قيمة J هتقل اكتر , بس بعد فترة معينة السلوب بيقرب لصفر , و بيكون فيه عدد ضخم جدا من المحاولات مع فرق بسيط , و هنا لازم نوقف , عشان هيكون ضياع وقت علي الفاضي
- ممكن نوقف بعد 5 او 50 او 5 مليون محاولة , محدش هيقدر يحدد الرقم كام , كل حالة بحالتها

قيمة ألفا

قيمة الفا ؟ ؟

- اختلافها يغير من سرعة التعامل , ودقته

repeat until convergence: {

$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_0^{(i)}$$

قيمة ألفا

قيمة الفا ؟ ؟

- لو زادت قيمة الفا هجري بسرعة ,بس ممكن اقع في مشكلة اني ازود قيمة الـ J , ولو مشيت ببطئ , هيكون دقيق بس بطئ جدا , فلازم اختار قيم مظبوطة